Python ile Makine Öğrenmesi

Bilal Kurban

bilal.kurban@tuik.gov.tr

https://github.com/bilalkurban/files

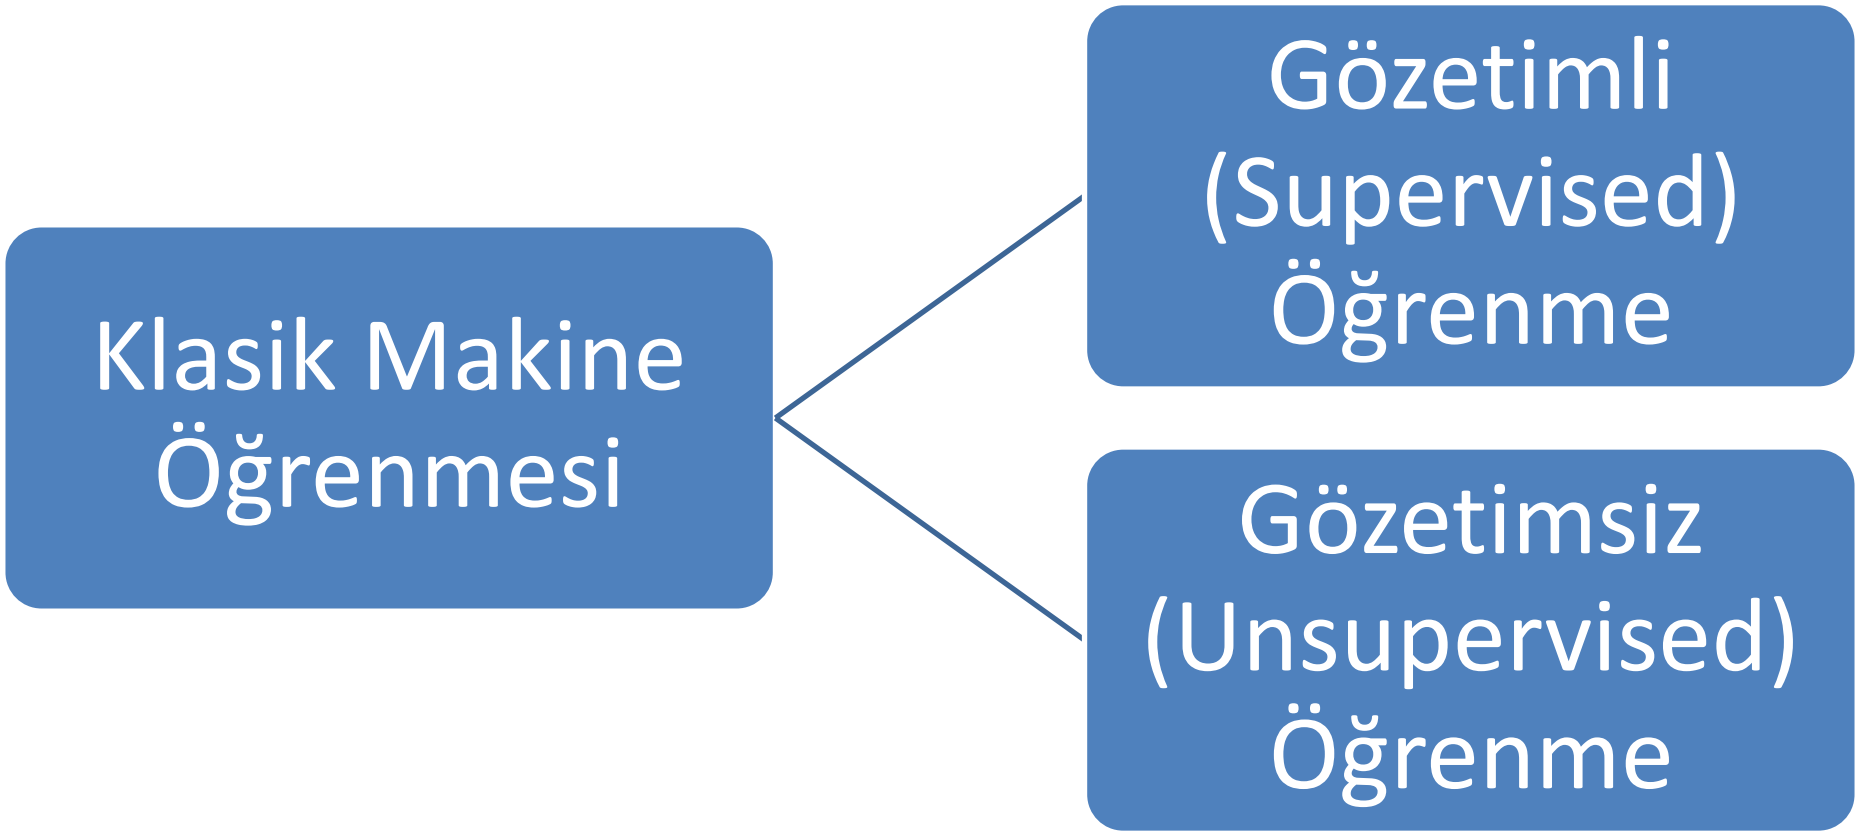
Klasik Makine Öğrenmesi
Gözetimli (Supervised) Öğrenme
Gözetimsiz (Unsupervised) Öğrenme

Gözetimli Öğrenme

- Görev güdümlü (bir sonraki değeri tahmin et)
- Önceden kategorize edilmiş veriler

Gözetimsiz Öğrenme

- Veri güdümlü (kümeleri tanımla)
- Etiketlenmemiş veriler

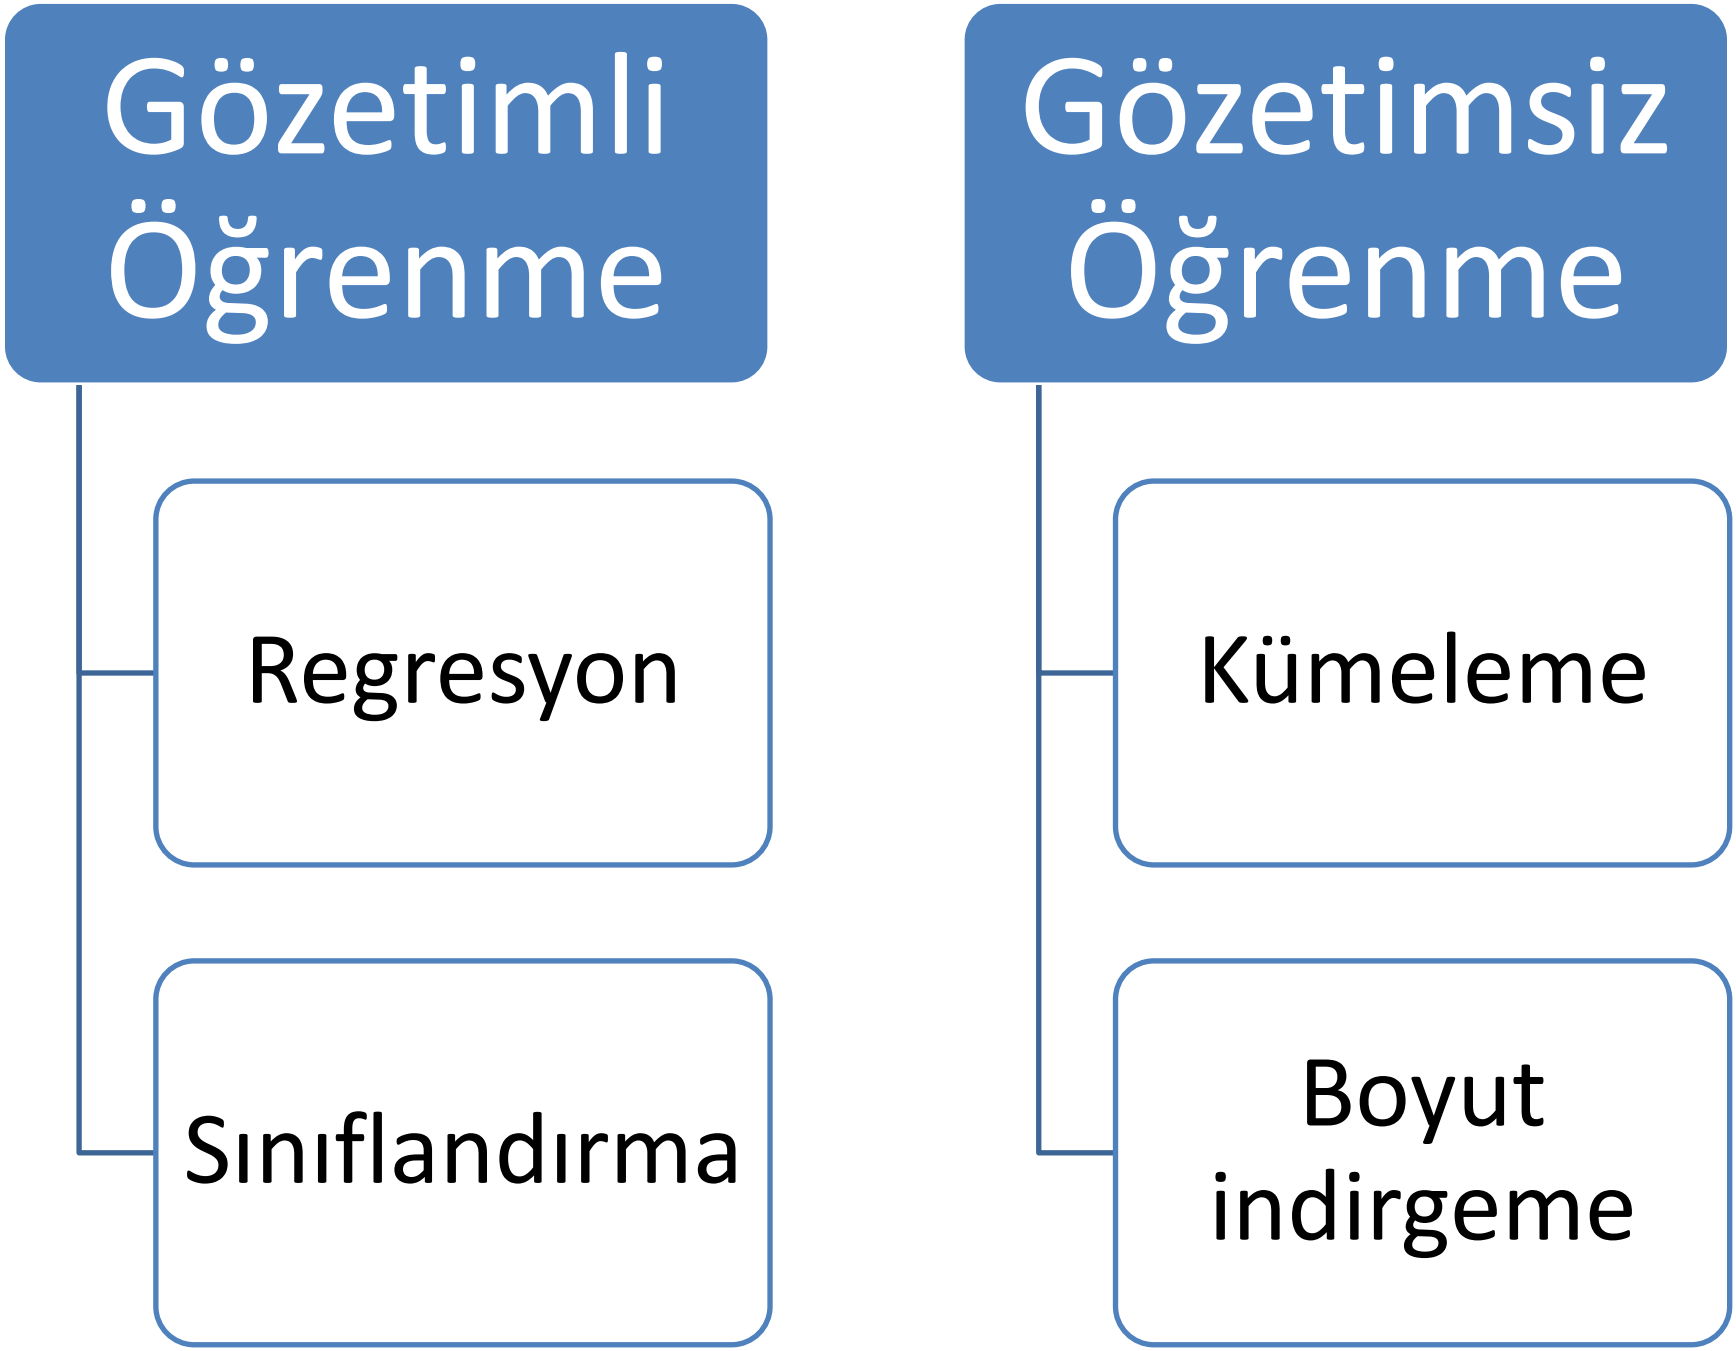
Gözetimli Öğrenme
Regresyon
Sınıflandırma
Gözetimsiz Öğrenme
Kümeleme
Boyut indirgeme

Gözetimli Öğrenme

Regresyon

- Risk değerlendirmesi
- Skor tahmini

Sınıflandırma

- Sahtekarlık tespiti
- Spam e-posta tespiti
- Tanılama
- İmaj sınıflandırması

Gözetimsiz Öğrenme

Kümeleme

- Hedef Pazar, Müşteri segmentasyonu
- Şehir Planlama
- Biyoloji

Boyut indirgeme

- Veri madenciliği
- Yüz tanıma

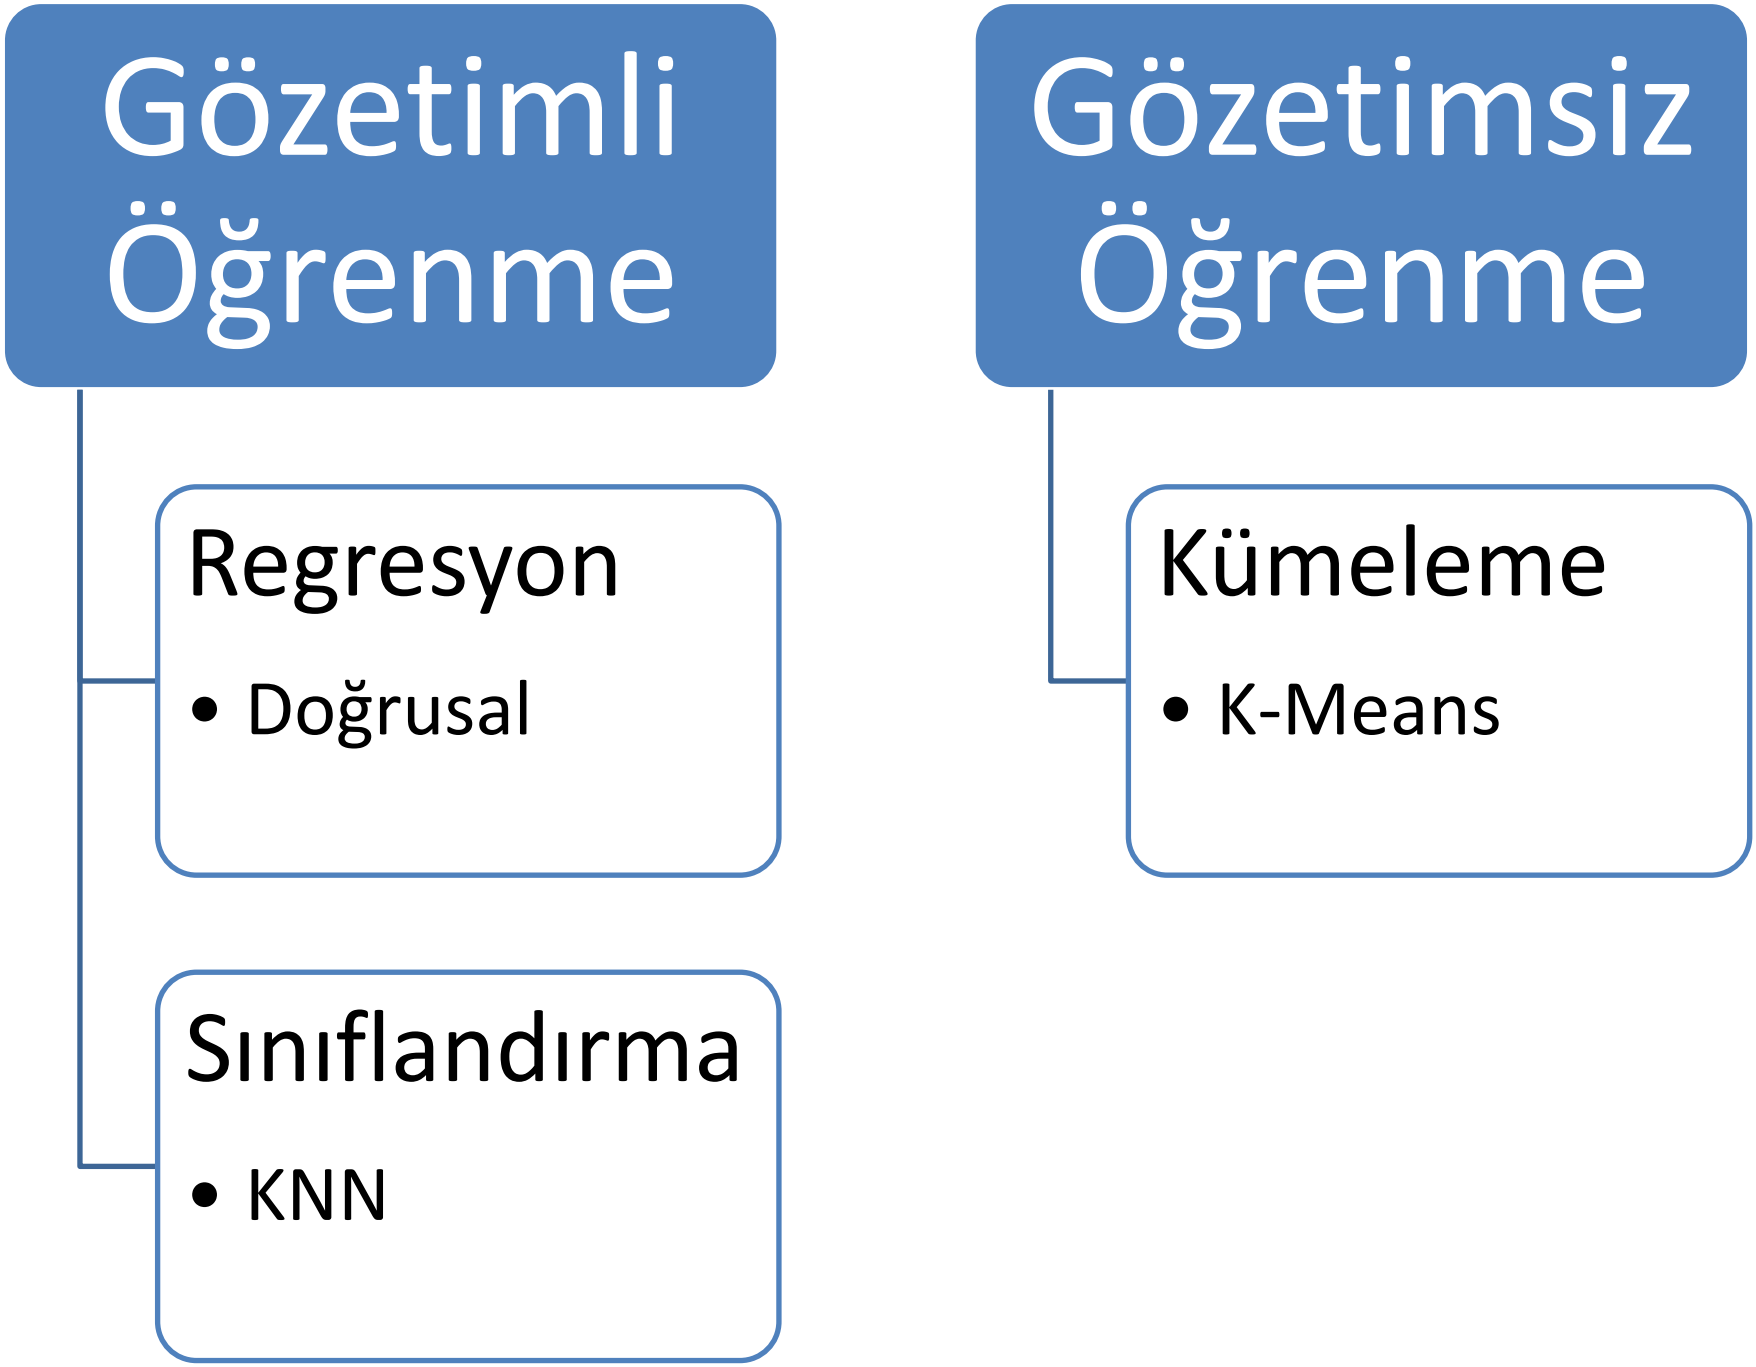
Gözetimli Öğrenme
Regresyon
• Doğrusal
Sınıflandırma
• KNN
Gözetimsiz Öğrenme
Kümeleme
• K-Means

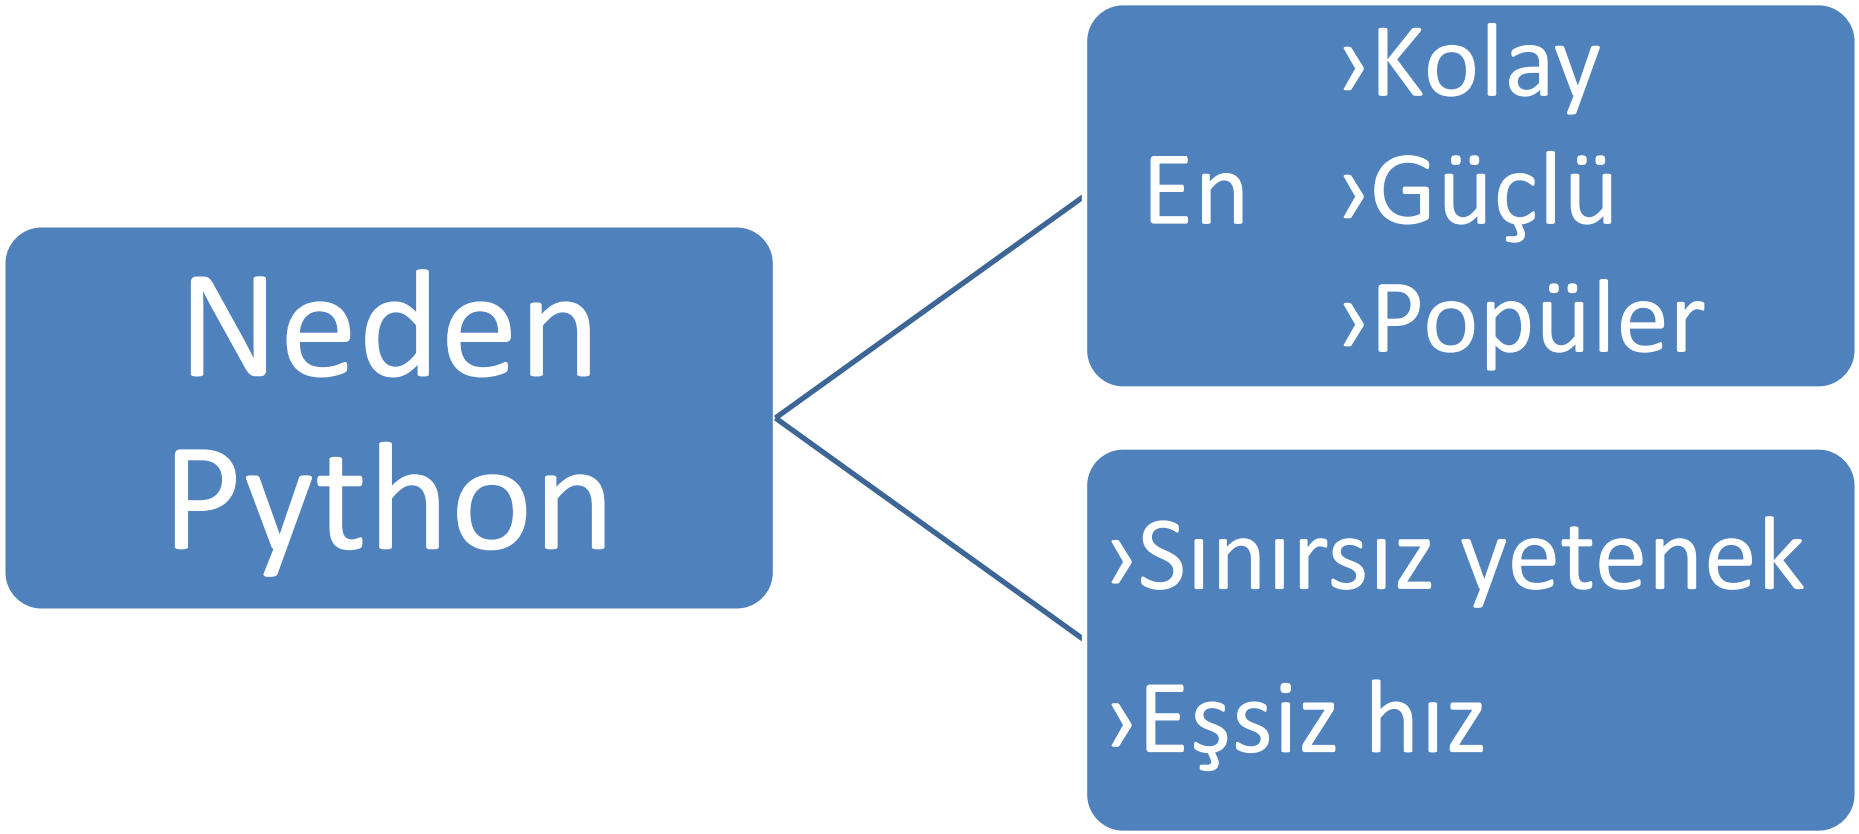
Neden Python
En
›Kolay
›Güçlü
›Popüler
›Sınırsız yetenek
›Eşsiz hız

Gözetimli Öğrenme

Regresyon

- Doğrusal

Sınıflandırma

- KNN

Gözetimsiz Öğrenme

Kümeleme

- K-Means

Python ile Çoklu Doğrusal Regresyon

- Emlak veri setimiz (emlak_fiyat_boyut_metro.csv)
- Bu veri setini kullanarak
  - Emlağın boyutu ve metroya yakınlığı verildiğinde fiyatını tahmin edebilecek bir Çoklu Doğrusal Regresyon modeli oluştur.
  - Sabit (intercept) ve katsayıları (coefficients) göster
  - R-kare (R-squared) ve düzeltilmiş R-kareyi (Adjusted R-squared) bul ve karşılaştır
  - Modeli kullanarak 120 metrekarelik ve metroya 10dk yakınlıkta bir dairenin fiyatı hakkında bir tahmin yap
  - İki değişkenin p-değerlerini bul ve yorumla.

İlgili kütüphaneleri içe aktar

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
sns.set()
from sklearn.linear_model import LinearRegression
```

Veriyi yükle

```
data = pd.read_csv('emlak_fiyat_boyut_metro.csv')
data.head()
```

	fiyat	boyut	metro_yakinlik
0	234314.144	98	15
1	228581.528	100	16
2	281626.336	74	13
3	401255.608	229	5
4	458674.256	194	4

Özelliklerin şekli

```
data.shape
```

```
(100, 3)
```

Tanımlayıcı istatistikler

```
data.describe()
```

	fiyat	boyut	metro_yakinlik
count	100.000000	100.000000	100.000000
mean	292289.470160	129.960000	12.980000
std	77051.727525	45.389876	6.485384
min	154282.128000	73.000000	1.000000
25%	234280.148000	98.000000	8.000000
50%	280590.716000	106.000000	12.500000
75%	335723.696000	157.000000	17.000000
max	500681.128000	281.000000	30.000000

Bağımlı, bağımsız değişkenleri bildir

```
x = data[['boyut','metro_yakinlik']]
y = data['fiyat']
```

Saçılım Grafiği (Boyut, Fiyat)

```
plt.scatter(x['boyut'],y)
plt.xlabel('Boyut', fontsize = 15)
plt.ylabel('Fiyat', fontsize = 15)
plt.show()
```

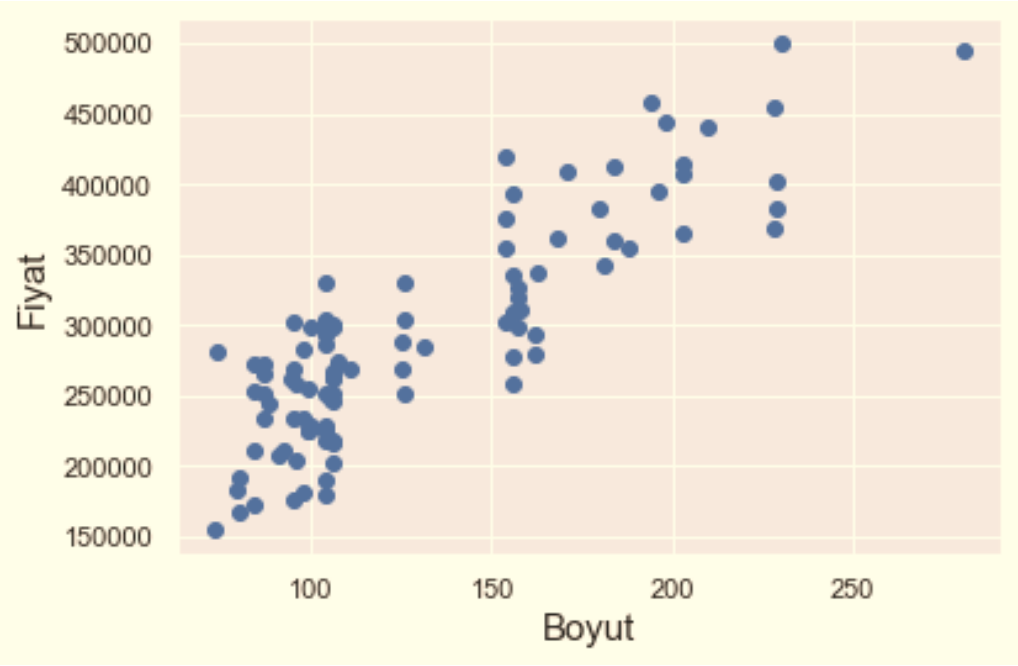

Saçılım Grafiği (Metroya yakınlık, Fiyat)

```
plt.scatter(x['metro_yakinlik'],y)
plt.xlabel('Metroya Yakınlık (dk)', fontsize = 15)
plt.ylabel('Fiyat', fontsize = 15)
plt.show()
```

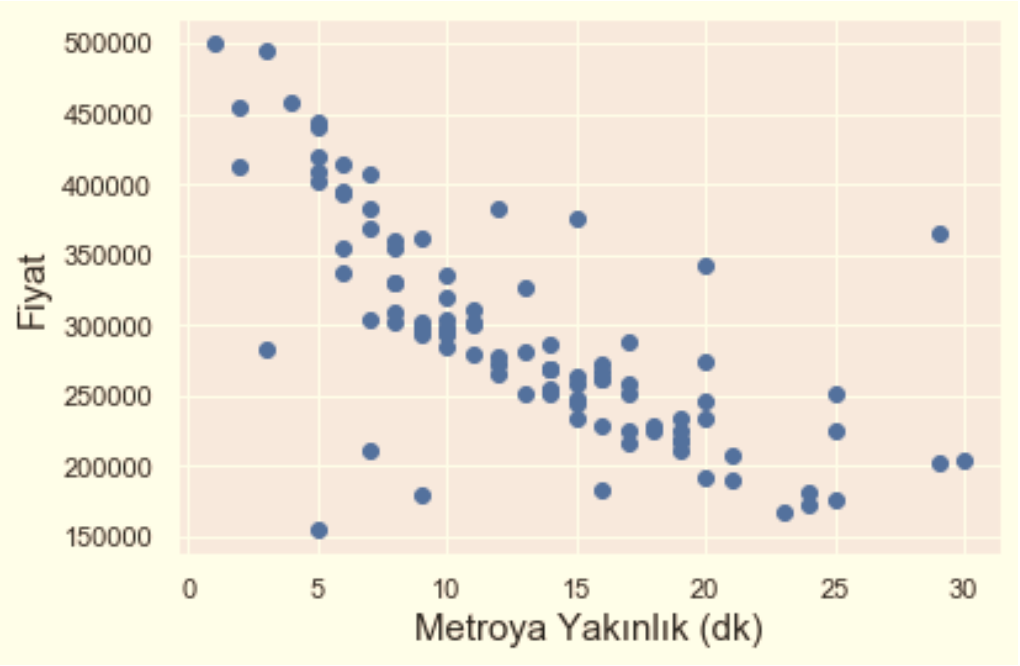

Regresyonu oluştur

```
reg = LinearRegression()
reg.fit(x,y)
```

```
LinearRegression(copy_X=True, fit_intercept=True,
n_jobs=None, normalize=False)
```

Sabit (kesim noktası) bul

```
reg.intercept_
```

```
194304.12416550127
```

Katsayıları bul

```
reg.coef_
```

```
array([ 1156.04485385, -4025.75063265])
```

R^2yi hesapla

```
reg.score(x,y)
```

```
0.8257742530054536
```

Düzeltilmiş R^2yi hesapla

```
r2 = reg.score(x,y)
n = x.shape[0]
p = x.shape[1]
duzeltilmis_r2 = 1-(1-r2)*(n-1)/(n-p-1)
duzeltilmis_r2
```

```
In [4]: data.shape
Out[4]: (100, 3)
```

$$R^2_{adj.} = 1 - (1 - R^2) * \frac{n-1}{n-p-1}$$

```
0.8221819695622671
```

Tahmin yapma

(120 metrekarelik ve metroya 10dk mesafede bir dairenin tahmini fiyatını bul)

```
reg.predict([[120,10]])
```

```
array([292772.00030096])
```

Çoklu tahmin için veri seti

```
yeni_data=pd.DataFrame({'boyut': [100,150,200],
'metro_yakinlik': [30,10,5]})
yeni_data
```

	boyut	metro_yakinlik
0	100	30
1	150	10
2	200	5

Çoklu tahmin değerleri

```
reg.predict(yeni_data).round(1)
```

```
array([189136.1, 327453.3, 405384.3])
```

Çoklu tahmini veri setine ekle

```
yeni_data['Tahmini_Fiyat'] = reg.predict(yeni_data)
yeni_data
```

	boyut	metro_yakinlik	Tahmini_Fiyat
0	100	30	189136.090571
1	150	10	327453.345916
2	200	5	405384.341772

Değişkenlerin p değerlerini hesapla

```
from sklearn.feature_selection import f_regression
f_regression(x,y)
```

```
(array([284.65801738, 96.07823108]),
array([9.55713521e-31, 3.25674570e-16]))
```

Değişkenlerin p değerlerini hesapla

```
p_values = f_regression(x,y)[1]
p_values.round(3)
```

```
array([0., 0.])
```


Gözetimli Öğrenme
Regresyon
• Doğrusal
Sınıflandırma
• KNN
Gözetimsiz Öğrenme
Kümeleme
• K-Means

Python ile KNN (K-en yakın komşu)

- Veri setimiz (iris)
- Bu veri setini kullanarak
  - Çiçek ölçülerinden çiçek türünü sınıflandıran bir model geliştir.
  - Modeli kullanarak sepal uzunluk:4.8, sepal genişlik:2.9, petal uzunluk:1.3, petal genişlik:0.3 olan bir çiçeğin hangi türe ait olduğunu tahmin et.
  - Modelin başarı oranını bul.

Veriyi yükle

```
import matplotlib.pyplot as plt
import seaborn as sns
iris=sns.load_dataset('iris')
iris.head(5)
```

	sepal_length	sepal_width	petal_length	petal_width	species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

İkili Çizimler

```
sns.pairplot(iris,hue='species')
plt.show()
```

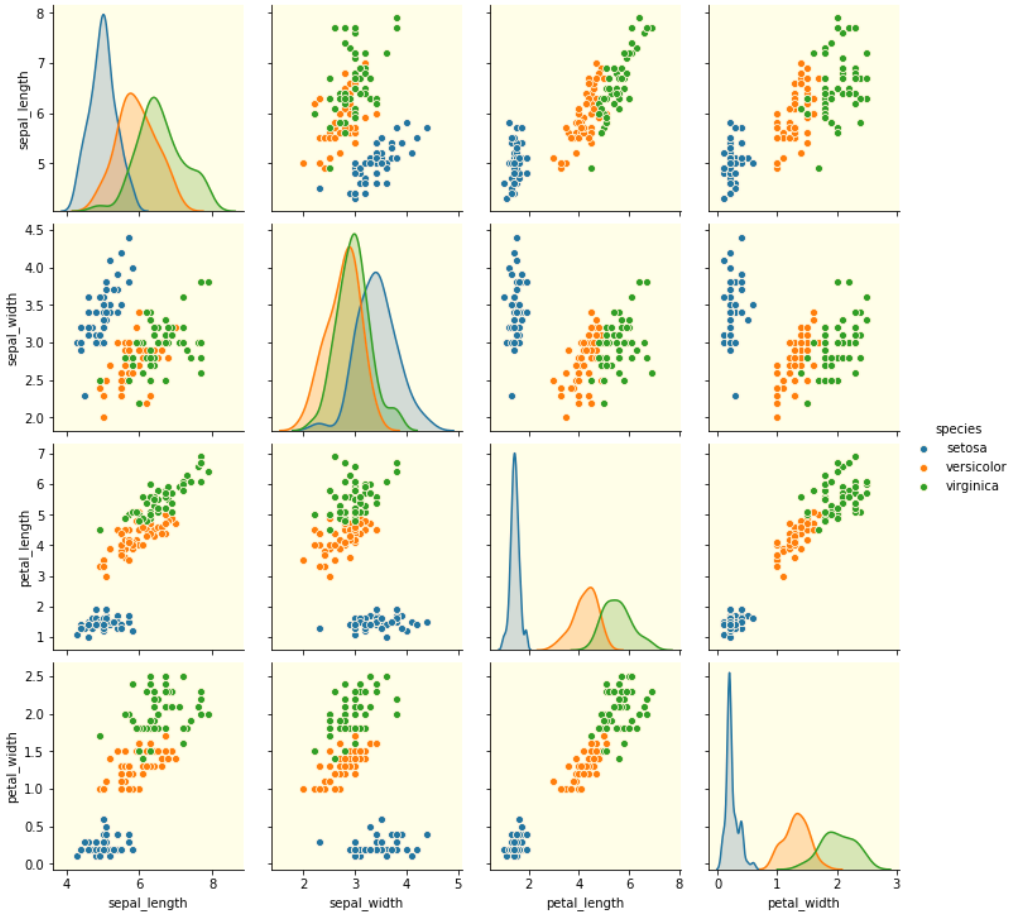

Taç Yaprak Genişliği ve Uzunluğu

```
sns.lmplot(x='petal_width',y='petal_length',data=iris,hue='species',fit_reg=False)
plt.xlabel('Taç Yaprak Genişliği (cm)')
plt.ylabel('Taç Yaprak Uzunluğu (cm)')
plt.show()
```

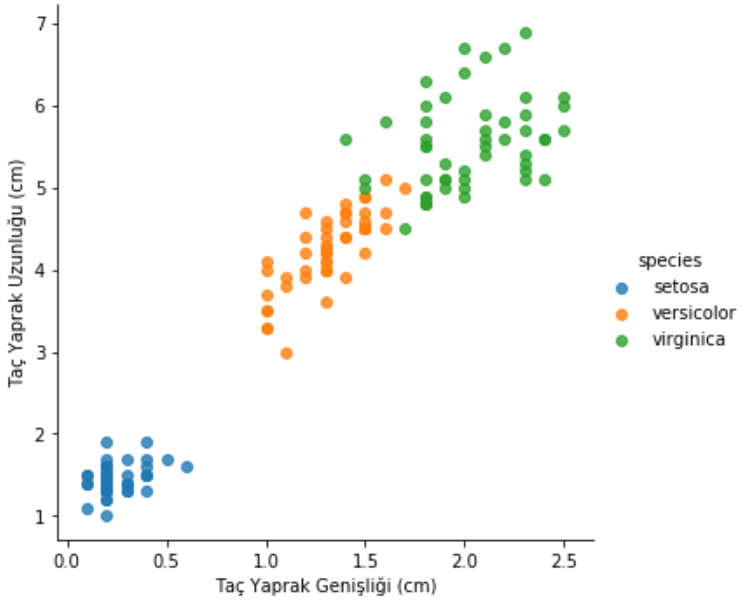

Modeli oluştur

```
from sklearn.neighbors import KNeighborsClassifier
en_yakin_k=KNeighborsClassifier(n_neighbors=5)
en_yakin_k.fit(iris[['sepal_length','sepal_width','petal_length','petal_width']],iris['species'])
```

```
KNeighborsClassifier(algorithm='auto', leaf_size=30,
metric='minkowski', metric_params=None,
n_jobs=1, n_neighbors=5, p=2, weights='uniform')
```

Tahmin

```
import pandas as pd
import numpy as np
cicek=np.array([[4.8,2.9,1.3,0.3]])
tahmin=en_yakin_k.predict(cicek)
tahmin_olasilik=en_yakin_k.predict_proba(cicek)
print(‘Çiçek Türü Tahmini:',tahmin)
print('Tahmin Olasılığı:',tahmin_olasilik)
```

```
Çiçek Türü Tahmini: ['setosa'] Tahmin Olasılığı: [[1.
0. 0.]]
```

Başarı oranı

```
x=iris[['sepal_length','sepal_width','petal_length','petal
_width']]
y=iris[['species']]
data=y.copy()
tahmin1=en_yakin_k.predict(x)
data['Tahmin y']=tahmin1
data['Aynımı']=data['species']==data['Tahmin y']
print('Başarı Sayısı',data.Aynımı.value_counts())
print('Başarı Oranı',data.Aynımı.value_counts('%'))
```

```
Başarı Sayısı True 145 False 5 Name: Aynımı, dtype:
int64 Başarı Oranı True 0.966667 False 0.033333
Name: Aynımı, dtype: float64
```


Gözetimli Öğrenme
Regresyon
• Doğrusal
Sınıflandırma
• KNN
Gözetimsiz Öğrenme
Kümeleme
• K-Means

Python ile K-means kümeleme

- Market veri setimiz (market_tatmin_sadakat.csv)
- Bu veri setini kullanarak
  - Verilerimizi çizelim
  - Müşterileri önce iki kümeye ayıralım.
  - Değişkenleri standartlaştıralım
  - K'nin seçimi
  - Dört küme

İlgili kütüphaneleri içe aktar

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
sns.set()
from sklearn.cluster import KMeans
```

Veriyi yükle

```
data = pd.read_csv(‘market_tatmin_sadakat.csv')
data.head()
```

	tatmin	sadakat
0	4	-1.33
1	6	-0.28
2	5	-0.99
3	7	-0.29
4	4	1.06

Verileri çiz

```
plt.scatter(data['tatmin'],data['sadakat'])
plt.xlabel('Tatmin')
plt.ylabel('Sadakat')
```

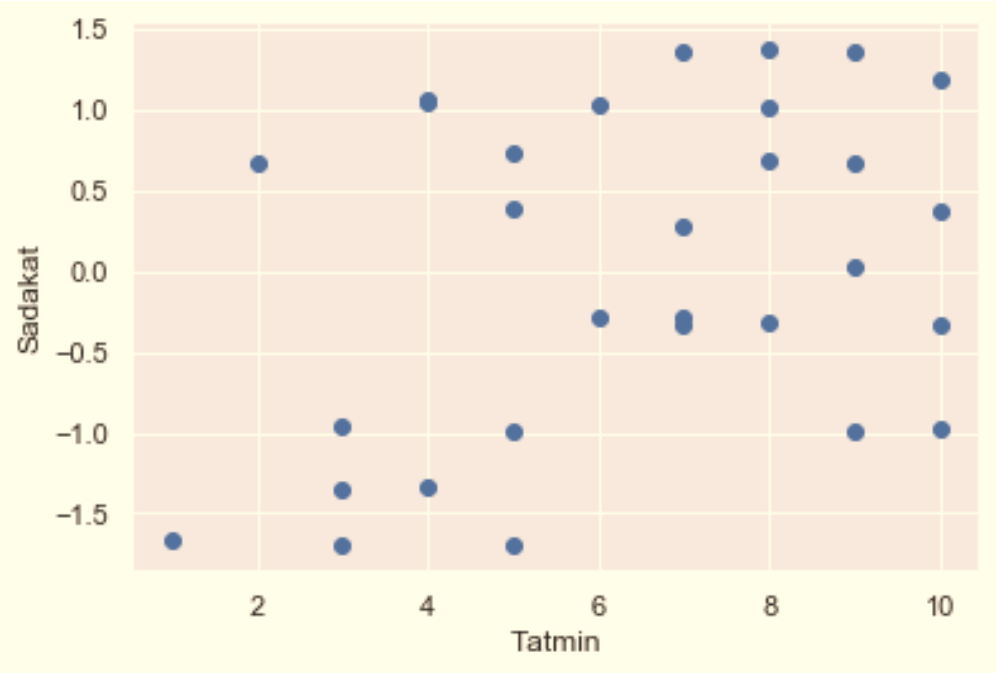

Kümeleme

```
x = data.copy()
kmeans = KMeans(2)
kmeans.fit(x)
```

```
KMeans(algorithm='auto', copy=True, init='k-means++', max_iter=300, n_clusters=2, n_init=10, n_jobs=None, precompute_distances='auto', random_state=None, tol=0.0001, verbose=0)
```

Kümeleme Sonuçları

```
clusters = x.copy()
clusters['kume_tahmin']=kmeans.fit_predict(x)
plt.scatter(clusters['tatmin'],clusters['sadakat'],c=cluste
rs['kume_tahmin'],cmap='rainbow')
plt.xlabel('Tatmin')
plt.ylabel('Sadakat')
```

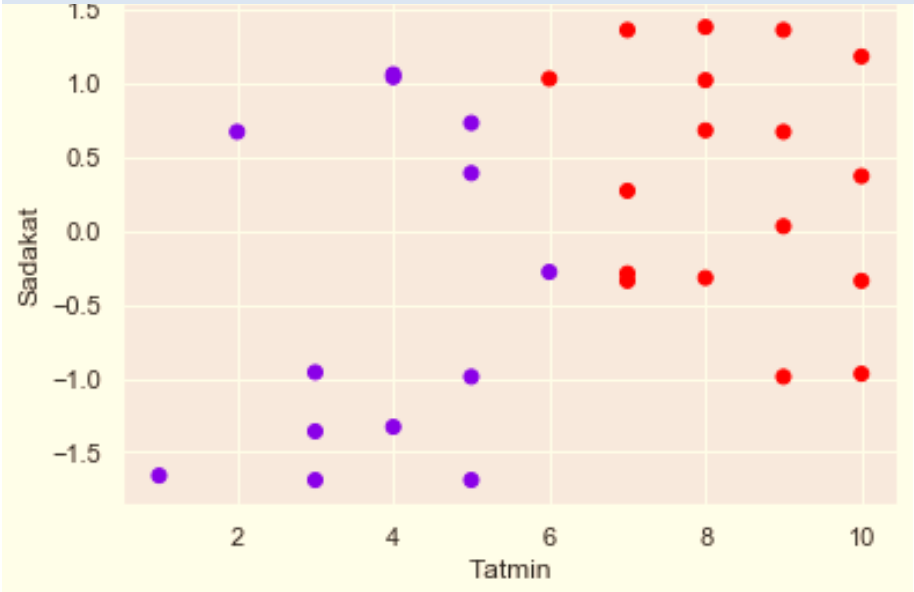

Değişkenleri standartlaştır

```
from sklearn import preprocessing
x_scaled = preprocessing.scale(x)
x_scaled
```

```
array([[-0.93138063, -1.3318111 ], [-0.15523011, -
0.28117124], [-0.54330537, -0.99160391], [
0.23284516, -0.29117733], [-0.93138063,
1.05964534], ..........
```

Standartlaştırma öncesi:					
tatmin	4	6	5	7	4
sadakat	-1.33	-0.28	-0.99	-0.29	1.06

K'yi Seçmek için Dirsek yöntemi

```
kikt =[]
for i in range(1,10):
    kmeans = KMeans(i)
    kmeans.fit(x_scaled)
    kikt.append(kmeans.inertia_)
kikt
```

```
[60.0,
 29.818973034723147,
 17.913349527387965,
 10.247181805928422,
 7.792695153937187,
 6.571285077136385,
 5.326631124753926,
 4.380320178840311,
 3.9293801253331493]
```

Dirsek çizimi

```
plt.plot(range(1,10),kikt)
plt.xlabel('Küme Sayısı')
plt.ylabel('Küme-içi Kareler Toplamı')
```

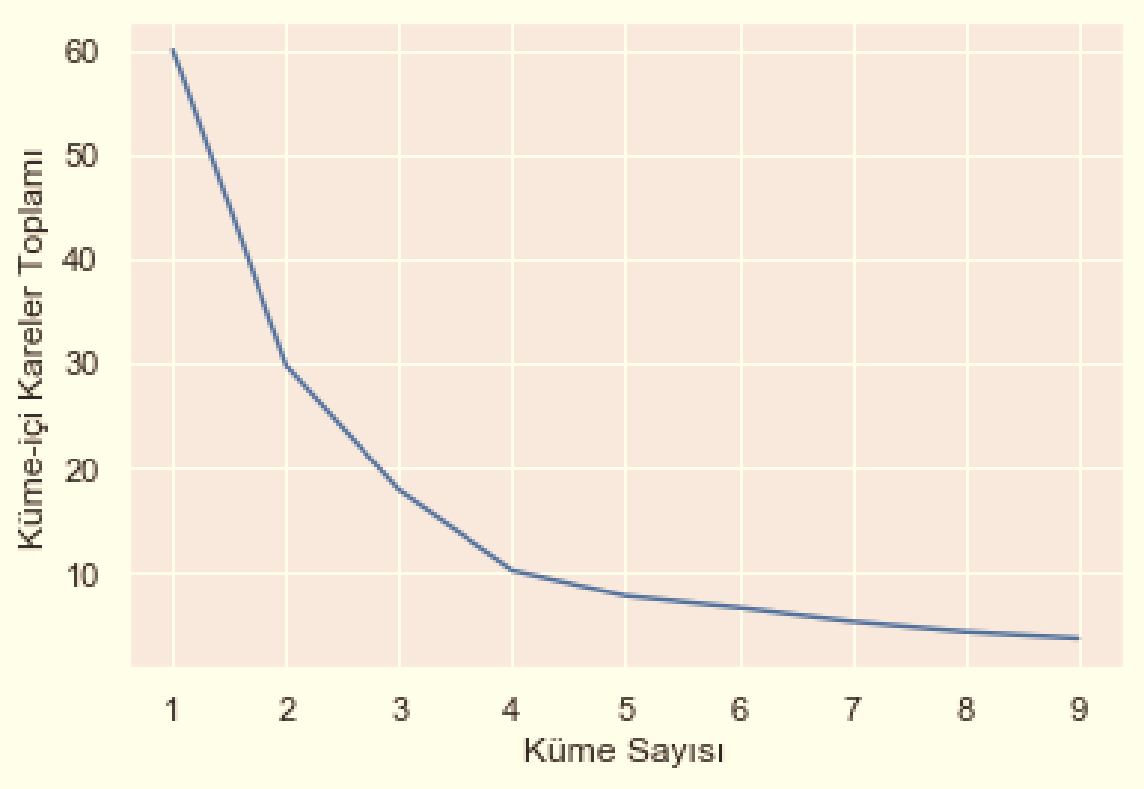

Kümeleme çözümlerini keşfedin

```
kmeans_new = KMeans(4)
kmeans_new.fit(x_scaled)
clusters_new = x.copy()
clusters_new['kume_tahmin'] =
kmeans_new.fit_predict(x_scaled)
```

Kümeleme çözümlerini keşfedin

```
clusters_new.head(8)
```

	tatmin	sadakat	kume_tahmin
0	4	-1.33	0
1	6	-0.28	3
2	5	-0.99	0
3	7	-0.29	3
4	4	1.06	2
5	1	-1.66	0
6	10	-0.97	3
7	8	-0.32	3

4’lü kümemizin çizimi

```
plt.scatter(clusters_new['tatmin'],clusters_new['sadakat'],c=clusters_new['kume_tahmin'],cmap='rainbow')
plt.xlabel('Tatmin')
plt.ylabel('Sadakat')
```

Market segmentasyonumuz (etiketli)

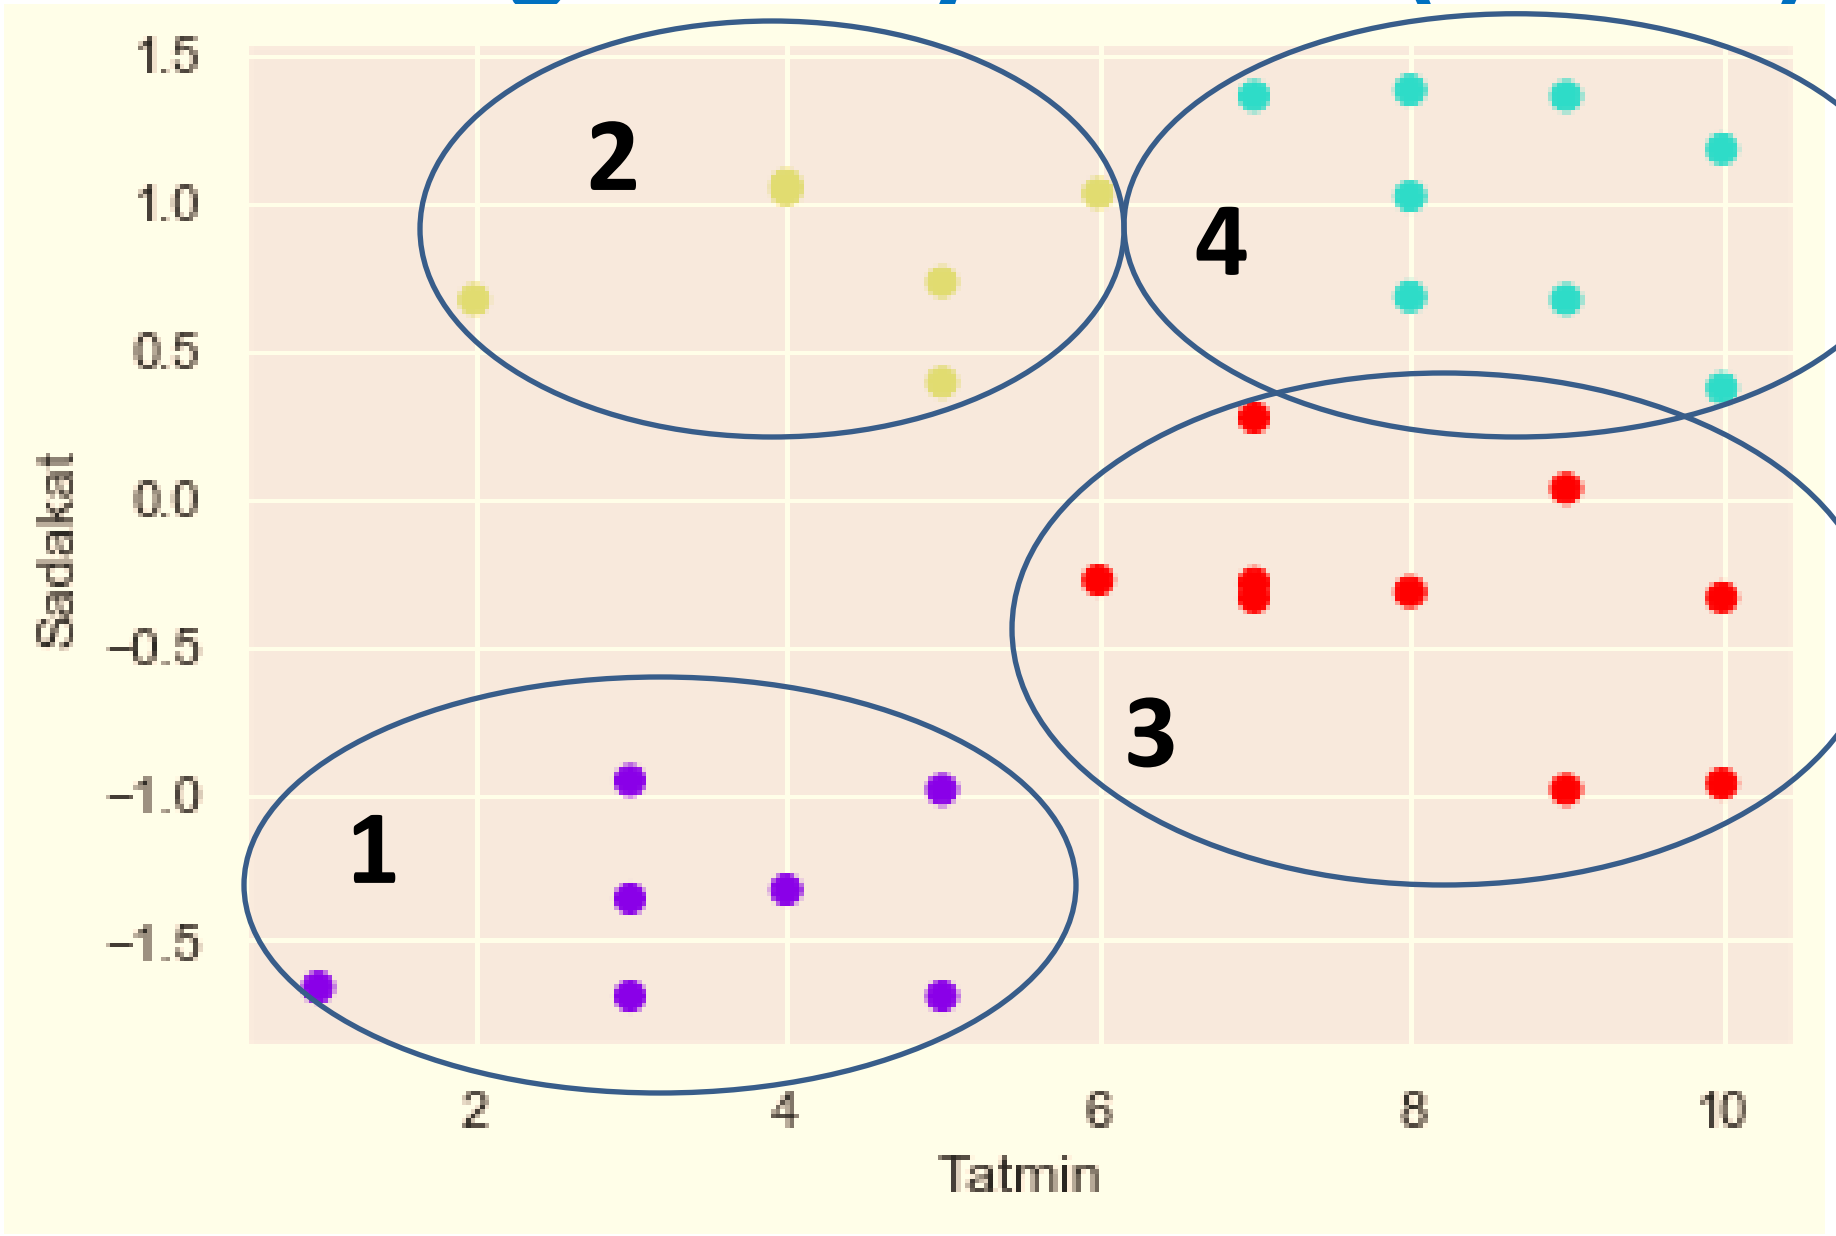

Teşekkürler.

```
print('Teşekkürler')
print('bilal.kurban@tuik.gov.tr')
```

```
Teşekkürler
bilal.kurban@tuik.gov.tr
```